

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação *Lato Sensu* em Inteligência Artificial e Aprendizado de Máquina

Vinício Silva Lima

PREDIÇÃO DE INSUFICIÊNCIA CARDÍACA

Belo Horizonte
Junho de 2022

Vinício Silva Lima

PREDIÇÃO DE INSUFICIÊNCIA CARDÍACA

Trabalho de Conclusão de Curso apresentado ao Curso de Especialização em Inteligência Artificial e Aprendizado de Máquina, como requisito parcial à obtenção do título de *Especialista*.

Belo Horizonte

Junho de 2022

SUMÁRIO

1. Introdução	4
2. Descrição do Problema e da Solução Proposta	5
3. Canvas Analítico	6
4. Coleta de Dados	6
5. Processamento/Tratamento de Dados	8
6. Análise e Exploração dos Dados	12
7. Preparação dos Dados para os Modelos de Aprendizado de Máquina	12
8. Aplicação de Modelos de Aprendizado de Máquina	12
9. Discussão dos Resultados	13
10. Conclusão	13
11. Links	13
12. Referências	13

1. Introdução

O ser humano tem a habilidade de aprender com os problemas e tomar decisões a partir de experiências já vividas. Quando nos referimos a computação, a Inteligência Artificial consegue, por meio de algoritmos complexos de Aprendizado de Máquina, encontrar padrões matemáticos para inferir resultados, de acordo com a necessidade das pessoas. Hoje, com o avanço da Inteligência Artificial, é possível realizar predições se um paciente tem uma pré-disposição a sofrer um ataque cardiovascular baseando-se em dados, tais como: idade, pressão arterial, colesterol, entre outros dados. Apesar disso, por incrível que pareça, ainda sofremos frequentemente com baixas relacionadas a problemas de insuficiência cardíaca, até mesmo em países mais desenvolvidos.

A insuficiência cardíaca aflige ou mata um em cada dois adultos nos Estados Unidos e em outros países desenvolvidos. (Go AS, Mozaffarian D, Roger VL, et al. 2013). Uma das causas dos ataques cardiovasculares é o acúmulo de placas de colesterol nas paredes internas de artérias, conhecido como aterosclerose. Normalmente o desenvolvimento da doença é silencioso e pode desenvolver-se na adolescência ou até mesmo na infância. Quando começa a apresentar sintomas, causa listras esbranquiçadas no revestimento interno das artérias que, com o passar do tempo, transformam-se em bolsas de colesterol que podem inchar-se, dificultando a passagem do fluxo sanguíneo na parede arterial, causando desconforto no peito. Em casos de rompimento das placas de colesterol, pode causar coágulos que, se muito grandes, podem impedir o fluxo sanguíneo e resultar em um ataque cardíaco ou um derrame. (Harvard T.H Chan School of Public Health, 2022).

A prática de atividade física regular reduz o risco de doenças cardíacas, diabetes, acidente vascular cerebral, pressão alta, osteoporose e até mesmo alguns tipos de câncer. (Harvard T.H Chan School of Public Health, 2022). Apesar disso, à medida que vamos envelhecendo, temos uma diminuição de atividade física, nos deixando mais expostos a doenças cardiovasculares (Matthews CE, George SM, Moore SC, et al. 2012).

Com base nisso, entendendo a importância deste tema, este trabalho tem como objetivo aplicar técnicas de Aprendizado de Máquina em uma base de dados de Insuficiência Cardíaca encontrada na plataforma de desafios de Ciência de Dados *Kaggle*. Por meio de modelos de classificação, podemos prever se os pacientes encontrados no *dataset* possuem insuficiência cardíaca ou não, apresentando todo o

processo de desenvolvimento do estudo como um todo e, desta forma, oferecer métricas de classificação efetivas para avaliar os modelos desenvolvidos.

2. Descrição do Problema e da Solução Proposta

Doenças cardiovasculares levam cerca de 17,9 milhões de vidas a cada ano, representando 31% de todas as mortes em todo mundo. Grande parte desses ataques de insuficiência cardíaca estão relacionados a problemas de acúmulo de placas de colesterol nas artérias. Independentemente do tamanho deste armazenamento de colesterol nas artérias, esses pacientes estão sujeitos a rompimentos inesperados nesses vasos, causando dores no peito e até mesmo derrames.

Não existe uma idade específica para um paciente ter o risco de sofrer de um ataque cardíaco. Infelizmente, muitas dessas vítimas sofrem de hipertensão, diabetes ou até mesmo hiperlipidemia.

Para evitar mais baixas de tantas pessoas, é importante que o diagnóstico de pacientes propensos a sofrerem de ataques cardíacos seja feito com antecedência. Neste requisito, modelos de Aprendizado de Máquina podem apoiar na detecção precoce de possíveis vítimas de doenças cardiovasculares, já que conseguem aprender com os padrões encontrados nas bases de dados e predizer se o paciente corre risco de ter um ataque cardíaco ou não.

Para resolver problemas de classificação, os modelos são comumente de Árvores de Decisão ou de Regressão Logística, por exemplo. Com as previsões feitas, os modelos são avaliados através de métricas de classificação (Recall, Precision, F1-Score, etc) e os resultados podem ser compartilhados com uma equipe de médicos, a fim de mostrar que a Inteligência Artificial pode ser uma grande aliada na prevenção de possíveis ataques cardiovasculares.

3. Canvas Analítico

Software Analytics Canvas

Project: Predição de Insuficiência Cardíaca

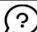
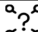


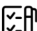


<div>1. Question</div> <p>What is it that we want to know about the software / processes / usage / organization / etc.?</p> <ul style="list-style-type: none">• É possível prever se o paciente é propenso a sofrer uma parada cardiovascular com os dados disponíveis?• Será que os níveis de colesterol apresentam uma forte correlação em relação a variável de insuficiência cardíaca?• Será que pessoas que sofreram de insuficiência cardíaca apresentaram comportamentos semelhantes?• Qual será a faixa etária das pessoas mais afetadas por insuficiência cardíaca?	<div>2. Data Sources</div> <p>Which data can possibly answer our question? What information do we need?</p> <ul style="list-style-type: none">• Dados relacionados aos resultados dos exames dos pacientes, tais como: Idade, Nível de Colesterol, Dor no Peito, Pressão Arterial, entre outras variáveis• Precisamos ter um dataset com dados consistentes para que o modelo treinado apresente bons resultados• Precisamos da nossa variável-alvo para realizarmos inferências e treinarmos o modelo de Aprendizado de Máquina	<div>3. Heuristics</div> <p>Which assumptions do we want to make to simplify the answer to our question?</p> <ul style="list-style-type: none">• Encontrar, por meio do estudo dos dados, características que possam resultar em casos de insuficiência cardíaca• Procurar possíveis correlações nos dados em relação a nossa variável-alvo• Documentar e realizar inferências estatísticas com base nos resultados encontrados	<div>4. Validation</div> <p>What results do we expect from our analysis, how are they reviewed and presented in an understandable way?</p> <ul style="list-style-type: none">• É esperado uma base com dados consistentes para treinarmos o modelo da melhor forma possível e oferecermos previsões relevantes• Os resultados serão analisados por meio métricas de classificação de modelos de Aprendizado de Máquina. Além disso, os resultados serão explicados de forma minuciosa na documentação do projeto, a fim de para facilitar o entendimento
<div>5. Implementation</div> <p>How can we implement the analysis step by step and in a comprehensible way?</p> <p>Para realizar o estudo, será aplicada a metodologia do CRISP-DM (Cross Industry Standard Process for Data Mining). Essa metodologia é iterativa, então, apesar de termos as etapas definidas, existe a flexibilidade de retornarmos nas etapas de acordo com a necessidade do negócio e resultados.</p> <p>O CRISP-DM pode ser dividido em algumas etapas:</p> <ul style="list-style-type: none">• Business understanding: Parte de entendimento do negócio e do problema a ser resolvido• Data Understanding: Entendimento inicial dos dados para entendermos como os dados estão distribuídos e quais abordagens serão necessárias para desenvolver o projeto• Data Preparation: Tratamento dos dados e criação de novas variáveis, a fim de potencializar o desempenho do modelo de acordo com as necessidades do negócio• Modeling: Desenvolvimento de modelos de Aprendizado de Aprendizado de Máquina• Evaluation: Análise do desempenho dos modelos desenvolvidos. Nesta etapa, validamos se o modelo treinado é capaz de realizar previsões relevantes para solução do problema• Deployment: Será feita a documentação dos resultados obtidos na pesquisa e as perguntas levantadas sendo respondidas baseadas nos estudos realizados	<div>6. Results</div> <p>What are the main insights from our analysis?</p> <ul style="list-style-type: none">• Evidenciar que a Inteligência Artificial pode ser uma grande aliada na prevenção de casos de problemas cardiovasculares• Entender quais variáveis foram mais relevantes para prever possíveis ataques de insuficiência cardíaca• Entender se existe correlação entre as variáveis estudadas e nossa variável-alvo	<div>7. Next Steps</div> <p>What follow-up actions can we derive from the findings? Who or what do we need to address next?</p> <ul style="list-style-type: none">• Como próximos passos, podemos solicitar novas bases de dados e entrar em contato com profissionais da área da saúde para ver como podemos melhorar mais o modelo preditivo e, como consequência, apoiá-los na prevenção de possíveis casos de insuficiência cardíaca	

Figura 1: Canvas Analítico

4. Coleta de Dados

A base de dados *Heart Failure Prediction Dataset* foi extraída na plataforma *Kaggle* por meio do seguinte link:

<https://www.kaggle.com/fedesoriano/heart-failure-prediction>. A extração foi feita no dia 20/06/2020.

A base é composta por *datasets* de pacientes dos Estados Unidos, Hungria, França e Suíça. Não foi fornecida a data de extração dos dados e a forma de como a base foi obtida.

Nome do dataset: Heart Failure Prediction Dataset

Descrição: *Dataset* com informações de pacientes americanos, suíços, franceses, húngaros com ou sem histórico de insuficiência cardíaca. O objetivo é analisar as variáveis e desenvolver um modelo capaz de realizar previsões de possíveis pacientes propensos a sofrer de insuficiência cardiovascular.

Data de publicação: 10/2022

Link: <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

Nome do Atributo	Descrição	Tipo
Age	Idade do paciente	Inteiro
Sex	Sexo do paciente	String
ChestPainType	Tipo de dor no peito	String
Cholesterol	Colesterol total	Inteiro
ExerciseAngina	Dor no peito proveniente do exercício	String
FastingBS	Glicose no sangue	Inteiro
MaxHR	Máxima de batimento cardíaco	Inteiro
Oldpeak	Depressão ST induzida por exercício relativamente sossegado	Float
RestingECG	Conclusão do Eletrocardiograma	String
ST_Slope	Taxa de frequência cardíaca	String
HeartDisease	Insuficiência Cardíaca (variável-alvo)	Inteiro

5. Processamento/Tratamento de Dados

Para realizar a análise, foi utilizado o *Jupyter Notebook* e as bibliotecas *pandas*, *numpy* e *category_encoders*

Import das bibliotecas

```
import pandas as pd
import numpy as np
from category_encoders.one_hot import OneHotEncoder
```

executed in 10.4s, finished 00:59:32 2022-06-15

Figura 2: import das bibliotecas

Para começar a análise, precisamos entender como os nossos dados estão distribuídos, conforme imagem abaixo:

```
#Lendo csv
df = pd.read_csv('heart.csv')
#Verificando a quantidade de linhas, colunas, nulos e o tipo de cada variável
df.info()
##Verificando as 3 primeiras linhas do dataframe
df.head(3)
```

executed in 110ms, finished 00:59:36 2022-06-15

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Age                   918 non-null   int64
1   Sex                   918 non-null   object
2   ChestPainType         918 non-null   object
3   RestingBP             918 non-null   int64
4   Cholesterol           918 non-null   int64
5   FastingBS             918 non-null   int64
6   RestingECG           918 non-null   object
7   MaxHR                 918 non-null   int64
8   ExerciseAngina        918 non-null   object
9   Oldpeak              918 non-null   float64
10  ST_Slope              918 non-null   object
11  HeartDisease          918 non-null   int64
dtypes: float64(1), int64(6), object(5)
memory usage: 86.2+ KB
```

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0

Figura 3: Leitura e entendimento inicial dos dados

Após importarmos o csv, podemos verificar que nossa base não possui variáveis nulas. Como temos atributos do tipo *object*, vamos precisar separar o nosso *dataframe* em duas partes para trabalharmos com as variáveis numéricas separadamente.

Separando as variáveis numéricas

```
#Selecionando as variáveis de formato numérico
atributos_numericos = df.select_dtypes(include=['int64', 'float64'])
#Verificando se as variáveis são numéricas
atributos_numericos.info()
```

executed in 16ms, finished 00:18:26 2022-06-15

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Age                    918 non-null    int64
1   RestingBP              918 non-null    int64
2   Cholesterol            918 non-null    int64
3   FastingBS              918 non-null    int64
4   MaxHR                  918 non-null    int64
5   Oldpeak                918 non-null    float64
6   HeartDisease           918 non-null    int64
dtypes: float64(1), int64(6)
memory usage: 50.3 KB
```

Figura 4: Separação das variáveis numéricas

Para separar as variáveis numéricas foi utilizada a função `select_dtypes` da biblioteca *pandas* e foi feito um filtro para selecionar as que possuem valores inteiros e *float*. Com o resultado atribuído à variável “atributos_numericos”, foi utilizada a função *info* para conferir os resultados.

Separando as variáveis em formato string e convertendo-as para formato categórico

```
#Selecionando as variáveis de formato object e transformando em categóricas
atributos_categoricos = df.select_dtypes(include=['object']).astype('category')
#Verificando se as variáveis são categóricas
atributos_categoricos.info()
```

executed in 27ms, finished 00:18:26 2022-06-15

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Sex                    918 non-null    category
1   ChestPainType          918 non-null    category
2   RestingECG             918 non-null    category
3   ExerciseAngina         918 non-null    category
4   ST_Slope               918 non-null    category
dtypes: category(5)
memory usage: 5.3 KB
```

Figura 5: Separação das variáveis categóricas

No caso das variáveis do tipo objeto foi feita uma conversão para formato categórico, pois temos atributos como “Sex” que apresenta resultados provenientes de categorias, como masculino e feminino. Após a atribuição do resultado à variável “atributos_categoricos”, realizamos a checagem se o tipo das variáveis foram convertidos para *object*.

Aplicando métricas estatísticas para entender as variáveis numéricas

```
# métricas de tendência central
# transpor para facilitar a visualização
ct1 = pd.DataFrame(atributos_numericos.apply(np.mean)).T # média
ct2 = pd.DataFrame(atributos_numericos.apply(np.median)).T # mediana
# métricas de dispersão
d1 = pd.DataFrame(atributos_numericos.apply(np.std)).T # desvio-padrão
d2 = pd.DataFrame(atributos_numericos.apply(min)).T # mínimo
d3 = pd.DataFrame(atributos_numericos.apply(max)).T # máximo
d4 = pd.DataFrame(atributos_numericos.apply(lambda x: x.max() - x.min())).T # range
d5 = pd.DataFrame(atributos_numericos.apply(lambda x: x.skew())).T # assimetria
d6 = pd.DataFrame(atributos_numericos.apply(lambda x: x.kurtosis())).T # curtose
# concatenar as métricas
m = pd.concat([d2, d3, d4, ct1, ct2, d1, d5, d6]).T.reset_index() # métricas
# nomear as colunas dos atributos concatenados
m.columns = ['Atributos', 'Min', 'Max', 'Range', 'Média', 'Mediana', 'Desvio-Padrão', 'Assimetria',
            'Curtose']
#Mostra tabela com os resultados
m
```

executed in 66ms, finished 00:18:27 2022-06-15

	Atributos	Min	Max	Range	Média	Mediana	Desvio-Padrão	Assimetria	Curtose
0	Age	28.0	77.0	49.0	53.510893	54.0	9.427478	-0.195933	-0.386140
1	RestingBP	0.0	200.0	200.0	132.396514	130.0	18.504067	0.179839	3.271251
2	Cholesterol	0.0	603.0	603.0	198.799564	223.0	109.324551	-0.610086	0.118208
3	FastingBS	0.0	1.0	1.0	0.233115	0.0	0.422815	1.264484	-0.401960
4	MaxHR	60.0	202.0	142.0	136.809368	138.0	25.446463	-0.144359	-0.448248
5	Oldpeak	-2.6	6.2	8.8	0.887364	0.6	1.065989	1.022872	1.203064
6	HeartDisease	0.0	1.0	1.0	0.553377	1.0	0.497143	-0.215086	-1.958008

Figura 6: Métricas estatísticas para entendimento de variáveis numéricas

Utilizando nossa variável “atributos_numericos” fizemos a declaração de alguns atributos e adicionamos medidas de dispersão para entendermos melhor os dados que estamos trabalhando. No caso, podemos observar que a variável de *Cholesterol* apresenta um desvio-padrão bem alto e um valor mínimo de 0, o que pode indicar possíveis valores inválidos na base.

Filtrando as colunas numéricas e entendendo um pouco a distribuição por quartil das variáveis

```
#Entendendo as variáveis numéricas
df.describe(include=['float64', 'int64'], percentiles=[0.01, .1, .25, .50, .75, .9, .99]).T
```

executed in 60ms, finished 00:18:27 2022-06-15

	count	mean	std	min	1%	10%	25%	50%	75%	90%	99%	max
Age	918.0	53.510893	9.432617	28.0	32.00	40.0	47.00	54.0	60.0	65.0	74.00	77.0
RestingBP	918.0	132.396514	18.514154	0.0	95.00	110.0	120.00	130.0	140.0	160.0	180.00	200.0
Cholesterol	918.0	198.799564	109.384145	0.0	0.00	0.0	173.25	223.0	267.0	305.0	411.49	603.0
FastingBS	918.0	0.233115	0.423046	0.0	0.00	0.0	0.00	0.0	0.0	1.0	1.00	1.0
MaxHR	918.0	136.809368	25.460334	60.0	77.17	103.0	120.00	138.0	156.0	170.0	186.00	202.0
Oldpeak	918.0	0.887364	1.066570	-2.6	-0.50	0.0	0.00	0.6	1.5	2.3	4.00	6.2
HeartDisease	918.0	0.553377	0.497414	0.0	0.00	0.0	0.00	1.0	1.0	1.0	1.00	1.0

Figura 7: Analisando as variáveis com quebras por quartil

Para nos aprofundarmos um pouco mais nas variáveis, foi aplicada a função *describe* com quebras por quartis para entendermos melhor como está a dispersão dos atributos. Com base nisso, podemos observar que a variável de *Cholesterol*

provavelmente possui *outliers*, já que o valor máximo encontrado está muito acima da média.

Concatenando os dados categoricos e numéricos

```
#Juntando as bases das variáveis numéricas e categóricas
df = pd.concat([atributos_categoricos, atributos_numericos], axis=1)
#Verificando as 3 primeiras linhas do dataframe
df.head(3)
```

executed in 33ms, finished 00:18:28 2022-06-15

	Sex	ChestPainType	RestingECG	ExerciseAngina	ST_Slope	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
0	M	ATA	Normal	N	Up	40	140	289	0	172	0.0	0
1	F	NAP	Normal	N	Flat	49	160	180	0	156	1.0	1
2	M	ATA	ST	N	Up	37	130	283	0	98	0.0	0

Figura 8: Junção de dataframes

Utilizando as variáveis “atributos_categoricos” e “atributos_numericos” podemos criar um novo *dataframe* concatenando as duas bases. Isso pode ser feito agora sem muitos impeditivos, já que o tipo dos atributos foram tratados anteriormente.

Filtrando colunas categoricas e aplicando o OneHotEncoder para classifica-las numericamente

```
#Filtrando as colunas categoricas
cols_encoding = df.select_dtypes(include='category').columns
#Passando para o OneHotEncoder as colunas categoricas
ohe = OneHotEncoder(cols=cols_encoding)
#Quebrando as variáveis categóricas em colunas numéricas
encoded = ohe.fit_transform(df)
#Verificando as 3 primeiras linhas do dataframe
encoded.head(3)
```

executed in 121ms, finished 00:18:28 2022-06-15

	Sex_1	Sex_2	ChestPainType_1	ChestPainType_2	ChestPainType_3	ChestPainType_4	RestingECG_1	RestingECG_2	RestingECG_3	ExerciseAngina_1	...	HeartDisease
0	1	0	1	0	0	0	1	0	0	1	...	0
1	0	1	0	1	0	0	1	0	0	1	...	1
2	1	0	1	0	0	0	0	1	0	1	...	0

3 rows x 21 columns

Figura 9: Aplicando o OneHotEncoder

Com o nosso novo *dataframe*, precisamos separar os valores categóricos novamente e atribuímos a uma variável temporária chamada “cols_encoding”. Feito isso, passamos as variáveis para o *OneHotEncoder* e aplicamos a transformação com o nosso método *fit*, quebrando nossas colunas de acordo com o número de categorias presentes em cada coluna. No caso de “ChestPainType”, existiam 4 categorias, então foram geradas quatro colunas distintas para separá-las.

6. Análise e Exploração dos Dados

Nessa etapa você começará a explorar seus dados de uma forma mais analítica, tentando elaborar ideias, levantar hipóteses e começando a identificar padrões em seus dados. Talvez você sinta a necessidade de voltar em passos anteriores, obter mais dados e tratá-los para conseguir responder ao problema proposto. Use e abuse de ferramentas estatísticas consistentes como testes de hipóteses e intervalos de confiança. Plote gráficos que te ajudem a obter insights interessantes: desde os mais simples até gráficos mais sofisticados como boxplots, mapas de calor, etc. Aqui o uso do Python e/ou R e suas poderosas bibliotecas gráficas (Matplotlib, Seaborn, ggPlot2, etc). Apresente trechos de código com as devidas justificativas.

7. Preparação dos Dados para os Modelos de Aprendizado de Máquina

Nesta etapa você deve descrever os tratamentos realizados especificamente para os modelos de Aprendizado de Máquina escolhidos, como por exemplo a criação de atributos, o balanceamento da base de dados (*undersampling* ou *oversampling*), divisão da base em treino, validação e teste, entre outros.

8. Aplicação de Modelos de Aprendizado de Máquina

Nesta seção você deve apresentar os modelos de Aprendizado de Máquina desenvolvidos no trabalho. Mostre partes do código-fonte para ilustrar a implementação de cada modelo, além do pipeline completo do processo. A escolha dos modelos deve ser adequada ao problema proposto. Embora possa ser considerado o uso de ferramentas como Weka, Knime e Orange, por exemplo, encoraja-se a implementação com linguagens como Python ou R. É importante testar mais de um tipo de algoritmo, para que resultados distintos possam ser comparados. Por exemplo, se o trabalho trata de uma classificação, modelos como Árvores de Decisão, Redes Neurais Artificiais e Support Vector Machine poderiam ser utilizados. Além disso, devem ser escolhidas e implementadas as métricas adequadas ao problema proposto, bem como os seus resultados apresentados.

9. Discussão dos Resultados

Nesta seção você deve relatar os resultados alcançados ao final do trabalho. Mostre os resultados das métricas adotadas, seja através de gráficos, tabelas, dentre outros, que permitam a validação do seu trabalho.

10. Conclusão

Nesta seção você deve apresentar um fechamento para o trabalho. É importante apresentar um breve resumo do trabalho, resgatando o problema, como foi tratado e os resultados obtidos, bem como as limitações e perspectivas (trabalhos futuros).

11. Links

Nesta seção você pode disponibilizar *links* para repositórios, como é o caso do GitHub, onde podem ser encontrados o seu projeto, códigos-fonte, vídeos demonstrativos, dentre outros.

12. Referências

Harvard Health Publishing Harvard Medical School. **Heart Health**. 2022. Disponível em: <<https://www.health.harvard.edu/topics/heart-health>> Acesso em 02/06/2022

Harvard T.H. Chan School of Public Health. **Heart Disease**. 2022. Disponível em: <<https://www.hsph.harvard.edu/nutritionsource/disease-prevention/cardiovascular-disease/>> Acesso em 02/06/2022

GO AS, Mozaffarian D, Roger VL, et al. **Heart disease and stroke statistics**, 2013. National Library of Medicine. Disponível em: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5408511/>> Acesso em 02/06/2022;

Matthews CE, George SM, Moore SC, et al. 2012. **Amount of time spent in sedentary behaviors and cause-specific mortality in US adults**. National Library of Medicine. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/22218159/>> Acesso em 02/06/2022

